

PROPOSAL INOVASI AI

AI Innovation Challenge · COMPFEST 18

“AI for the Backbone of the Economy” — Smart Commerce & Smart Logistics

AEO

AI Exception Orchestrator

Orkestrasi Respons Eksepsi Rantai Pasok Berbasis AI
dengan Kendali Manusia dan Kuantifikasi Kerugian

Nama Kelompok : cupuu
Judul Inovasi : AEO — AI Exception Orchestrator
Anggota Tim : Frederick Allensius
Kang Nicholas Darren Nugroho
Ivan William Lianata
Jennifer Carla
Derry Riccardo
Tahun : 2026

*Proposal ini disusun untuk memenuhi persyaratan
tahap penyisihan AI Innovation Challenge COMPFEST 18*

Daftar Isi

1	Latar Belakang	3
1.1	Konteks: Rantai Pasok sebagai Tulang Punggung Ekonomi Digital	3
1.2	Masalah: Bukan Kekurangan Data, Melainkan Kekurangan Respons	3
1.3	Posisi terhadap Solusi yang Sudah Ada	4
1.4	Urgensi dan Relevansi Global	5
2	Tujuan dan Manfaat Pengembangan	5
2.1	Tujuan Pengembangan	5
2.2	Manfaat Pengembangan	6
3	Metodologi	6
3.1	Alur dalam Memperoleh Dataset	6
3.1.1	Pemilihan Sumber Data dan Justifikasinya	6
3.1.2	Komposisi Dataset dan Alur Prapemrosesan	6
3.2	Alur Pengembangan Model (per Fitur)	7
3.2.1	Justifikasi Pemilihan Algoritma	8
3.2.2	Tahap 1: Deteksi Anomali (Isolation Forest)	8
3.2.3	Tahap 2: Kuantifikasi Dampak (LightGBM)	9
3.2.4	Tahap 3: Optimasi Pemulihan (OR-Tools CP-SAT)	10
3.2.5	Tahap 4: Autonomous Commerce Mitigation (LightGBM + Gemini 2.5 Flash)	11
3.3	Alur Integrasi Model ke Environment Kode	12
3.3.1	Arsitektur Sistem	12
3.3.2	Alur Integrasi Langkah demi Langkah	13
3.3.3	Ringkasan Endpoint API	14
4	Metode Pendukung Pengambilan Keputusan	14
4.1	Lapisan Explainability	14
4.2	Stratifikasi Severity	14
4.3	Dynamic Pricing Logic	14
4.4	Competitor-Aware Dynamic Sourcing	15
4.5	Demo Fallback dan Konvensi Pengembangan	15
5	Business Value dan Tata Kelola	15
5.1	Model Bisnis	15
5.2	Analisis Kelayakan Adopsi Industri	16
5.3	Tata Kelola AI dan Kepatuhan Regulasi	16
5.3.1	Perlindungan Data Pribadi	16
5.3.2	Klasifikasi Risiko dan Standar Internasional	17
5.3.3	Etika dan Sistem Cerdas yang Bertanggung Jawab	17
6	Proses Pengembangan Iteratif	18

7	Ruang Lingkup MVP, Keterbatasan, dan Rencana Pengembangan	18
7.1	Batas Ruang Lingkup yang Ditetapkan	18
7.2	Keterbatasan yang Kami Akui	19
7.3	Rencana Pengembangan menuju Babak Final	19
8	Kesimpulan	20

1. Latar Belakang

1.1. Konteks: Rantai Pasok sebagai Tulang Punggung Ekonomi Digital

Ekonomi digital Indonesia adalah yang terbesar di Asia Tenggara, dengan nilai transaksi bruto yang menurut laporan *e-Conomy SEA* berada pada kisaran USD 90 miliar pada 2024 dan *e-commerce* sebagai kontributor dominan [1]. Namun nilai transaksi hanyalah permukaan. Yang menopang angka tersebut adalah **rantai pasok**: jaringan pemasok, gudang, dan kurir yang harus mengeksekusi jutaan janji pengiriman setiap hari.


Kerapuhan rantai pasok bukan isu baru: Christopher & Peck [2] mendefinisikan *resilience* sebagai kemampuan sistem kembali stabil setelah gangguan, sementara Tang [3] menunjukkan strategi mitigasi statis tidak memadai karena gangguan bersifat multipenyebab dan saling bersusulan. Ivanov [4] membuktikan secara kuantitatif bahwa satu gangguan lokal dapat merambat menjadi *ripple effect* yang membesar di sepanjang rantai — prinsip yang menjustifikasi mengapa **deteksi dini** pada level transaksi adalah syarat mutlak, bukan fitur tambahan.

Janji itu sering gagal ditepati. Dalam operasional *e-commerce* berskala besar, **eksepsi rantai pasok** — lonjakan permintaan mendadak (*demand spike*), keterlambatan pemasok (*supplier delay*), dan gangguan pengiriman (*shipment delay*) — terjadi hampir setiap hari. Pada dataset Olist, dari 96.475 pesanan yang dianalisis, proporsi pesanan yang melewati tanggal estimasi pengiriman berada pada level dua digit persen. Literatur ekonomi retensi menunjukkan biaya akuisisi pelanggan baru jauh melampaui biaya retensi [5], dan bahwa nilai pelanggan harus dipandang sebagai aliran laba jangka panjang (*customer lifetime value*), bukan transaksi tunggal [6]. Dengan kerangka itu, satu pesanan yang gagal adalah ancaman terhadap aliran laba multi-tahun yang direpresentasikan pelanggan tersebut.

1.2. Masalah: Bukan Kekurangan Data, Melainkan Kekurangan Respons

Perusahaan besar sudah punya *dashboard*. Yang tidak mereka punya adalah **jembatan dari sinyal ke keputusan**. Ketika sebuah anomali muncul di layar, operator masih harus mengerjakan empat hal secara manual dan berurutan: menafsirkan apakah ini benar masalah, memperkirakan seberapa mahal dampaknya, memikirkan opsi pemulihan, lalu menghubungi pelanggan. Rangkaian ini memakan waktu berjam-jam, dan selama itu — sejalan dengan mekanisme perambatan gangguan Ivanov [4] — kerugian terus membesar, bukan tetap konstan.

Kami mengidentifikasi rantai kegagalan tersebut menjadi tiga kesenjangan spesifik yang saling memperkuat:



Gambar 1: Rantai kesenjangan dalam penanganan eksepsi rantai pasok. Ketiganya bersifat berurutan — menutup satu saja tidak memutus rantai kerugian.

Implikasi penting dari Gambar 1: menutup hanya satu kesenjangan tidak cukup. Sistem yang mendeteksi lebih cepat tetapi tidak mengkuantifikasi dampak hanya memindahkan beban *triage* ke operator. Sistem yang mengkuantifikasi tetapi tidak merekomendasikan aksi hanya menghasilkan laporan yang lebih rapi. **Nilai muncul justru dari orkestrasi keempat tahap sebagai satu alur.** Inilah premis desain AEO.

1.3. Posisi terhadap Solusi yang Sudah Ada

Kategori perangkat lunak rantai pasok bukan ruang kosong. Kami memetakan tiga kelas solusi eksisting dan menempatkan AEO secara eksplisit terhadapnya.

Tabel 1: Pemetaan AEO terhadap kelas solusi yang telah ada

Kelas Solusi	Yang Sudah Dilakukan	Yang Belum Ditutup
Suite perencanaan enterprise	Perencanaan permintaan dan inventori jangka menengah, akurasi tinggi pada horizon mingguan/bulanan.	Berorientasi <i>planning</i> , bukan respons insiden harian. Biaya lisensi dan implementasi di luar jangkauan pelaku menengah.
<i>Visibility & tracking</i>	Pelacakan posisi pengiriman dan notifikasi keterlambatan secara <i>real-time</i> .	Berhenti pada pemberitahuan . Tidak mengkuantifikasi kerugian, tidak merekomendasikan aksi.
Aturan internal (<i>rule engine</i>)	Murah, transparan, mudah diaudit oleh tim operasional.	Ambang statis, tidak belajar dari pola historis, dan tidak menimbang <i>trade-off</i> biaya antar opsi pemulihan.
AEO	Mengisi celah di antara ketiganya: berorientasi respons insiden (bukan perencanaan), berhenti bukan di notifikasi melainkan di opsi aksi terurut dengan angka rupiah , dan menggunakan model yang belajar dari data historis alih-alih ambang statis — sambil tetap menempatkan operator sebagai pengambil keputusan akhir.	

1.4. Urgensi dan Relevansi Global

Masalah ini mendesak karena tiga alasan: margin *e-commerce* yang tipis membuat kompensasi keterlambatan langsung menggerus profitabilitas; biaya akuisisi pelanggan jauh melampaui biaya retensi sehingga kehilangan pelanggan adalah kerugian majemuk; dan geografi kepulauan Indonesia membuat rantai pasok secara struktural lebih rentan terhadap gangguan multimoda dibanding negara daratan.

Meski dirancang dengan konteks Indonesia, masalah yang ditangani bersifat universal — setiap operasi *e-commerce* lintas negara menghadapi eksepsi pemasok, lonjakan permintaan, dan gangguan logistik. Arsitektur AEO tidak mengandung asumsi khas Indonesia pada lapisan modelnya; lokalisasi hanya menyentuh mata uang, bahasa pesan pelanggan, dan kalender musim belanja. Inilah yang membuatnya dapat direplikasi ke pasar lain tanpa perombakan model.

2. Tujuan dan Manfaat Pengembangan

2.1. Tujuan Pengembangan

1. Membangun *ensemble* deteksi anomali yang mengidentifikasi lonjakan permintaan, keterlambatan pemasok, dan gangguan pengiriman secara **independen dan simultan**, sehingga satu jenis eksepsi tidak menutupi jenis lain.
2. Mengkuantifikasi dampak setiap eksepsi menjadi **angka rupiah**, agar prioritas mengikuti besaran kerugian — bukan urutan kemunculan di layar.
3. Mengotomasi pemilihan aksi pemulihan melalui *constraint programming*, sehingga opsi yang direkomendasikan terbukti minimum secara matematis di antara kandidat yang layak.
4. Menurunkan risiko *churn* pascakegagalan melalui modul ACM yang memadukan prediksi churn dengan kompensasi bertingkat berbasis CLV dan pesan personal berbahasa Indonesia.
5. Mempertahankan **Human-in-the-Loop** pada setiap keputusan tak-terbalikkan, mengikuti kaidah interaksi manusia–AI bahwa sistem harus menampilkan tingkat keyakinannya dan memberi jalan mudah bagi manusia mengoreksi atau menolak keluaran [7], sehingga sistem menjadi penguat kapasitas operator, bukan penggantinya.

2.2. Manfaat Pengembangan

Tabel 2: Manfaat pengembangan AEO menurut pemangku kepentingan

Pemangku Kepentingan	Manfaat	Mekanisme yang Menghasilkannya
Operator rantai pasok	Respons lebih cepat, beban <i>triage</i> turun	Antrian eksepsi terurut otomatis berdasarkan <i>severity</i> gabungan; opsi pemulihan sudah terhitung saat halaman dibuka.
Manajemen finansial	Prioritisasi berbasis angka	Estimasi kerugian per eksepsi dalam IDR memungkinkan alokasi perhatian ke gangguan bernilai tertinggi.
Pelanggan akhir	Kompensasi proporsional dan komunikasi lebih manusiawi	Voucher bertingkat sesuai CLV serta pesan personal berbahasa Indonesia, bukan notifikasi generik.
Tim kepatuhan & organisasi	Jejak audit lengkap, adopsi AI berisiko rendah	Setiap keputusan tercatat dengan waktu, opsi terpilih, dan estimasi dampak; seluruh aksi tersimulasi hingga disetujui manusia.

3. Metodologi

3.1. Alur dalam Memperoleh Dataset

3.1.1. Pemilihan Sumber Data dan Justifikasinya


Dataset yang digunakan adalah **Olist Brazilian E-Commerce Public Dataset** yang tersedia terbuka di Kaggle [8], mencakup 96.475 pesanan periode 2016–2018 beserta data pengiriman, ulasan, penjual, dan produk.

Pemilihan ini adalah keputusan sadar dengan *trade-off* yang kami akui terbuka. Tidak tersedia dataset publik *e-commerce* Indonesia yang memuat **empat kolom yang mutlak dibutuhkan** secara bersamaan: waktu estimasi pengiriman, waktu pengiriman aktual, identitas penjual, dan skor ulasan. Tanpa keempatnya, label SLA *breach* dan label risiko churn tidak dapat dibentuk sama sekali.

Keterbatasan yang kami sadari: struktur biaya logistik dan perilaku pelanggan Brasil tidak identik dengan Indonesia, sehingga konversi mata uang diperlakukan sebagai **faktor demonstrasi yang dapat dikonfigurasi**, bukan klaim akurasi finansial. Yang kami ambil dari Olist adalah **struktur relasional dan pola statistiknya** — keterlambatan berdistribusi *right-skewed*, keandalan pemasok bervariasi tajam antar penjual, dan ulasan buruk berkorelasi dengan keterlambatan. Ketiga pola ini universal, dan itulah yang dipelajari model.

3.1.2. Komposisi Dataset dan Alur Prapemrosesan

Delapan berkas CSV ditempatkan di `backend/data/raw/olist/`. Skrip `backend/data/pipeline.py` melakukan seluruh prapemrosesan dan menghasilkan empat tabel fitur.



Gambar 2: Alur prapemrosesan: dari delapan berkas mentah menjadi empat tabel fitur, masing-masing dikonsumsi model yang sesuai. Tabel `order_features` dipakai dua kali (kuantifikasi dampak dan deteksi pengiriman).

Tabel 3: Tabel fitur hasil *feature engineering* dan turunan utamanya


Fungsi Pipeline	Keluaran	Fitur Utama
build_order_-features	Fitur per pesanan	delay_days, carrier_delay_days, sla_breach, order_value, purchase_hour, purchase_dow, purchase_month, item_count
build_demand_-timeseries	Velocitas harian per produk	order_count, rolling_mean_7d, rolling_std_7d, z_score
build_seller_-features	Keandalan per penjual	mean_delay, std_delay, late_rate, reliability (0–1)
build_customer_-features	CLV & churn per pelanggan	clv_score, total_spend, avg_review, late_deliveries, churn_risk_label

Dua turunan patut disorot karena merupakan **rekayasa fitur orisinal tim**, bukan kolom bawaan dataset:

- `clv_score` disusun sebagai kombinasi berbobot $0,6 \log(1 + \text{total_spend}) + 0,3 \text{order_count} + 0,1 (\text{avg_review}/5)$, lalu dinormalisasi *min–max* ke rentang $[0, 1]$. Transformasi logaritmik dipilih karena distribusi belanja sangat *right-skewed*; tanpa itu, segelintir pelanggan korporat akan mendominasi skala dan seluruh pelanggan ritel akan terkompresi mendekati nol.
- `reliability` didefinisikan sebagai $1 - \text{late_rate}$ per penjual, memberi satu angka yang langsung dapat diinterpretasi operator maupun dikonsumsi model.

3.2. Alur Pengembangan Model (per Fitur)

AEO terdiri atas empat tahap AI berurutan. Setiap tahap menyelesaikan sub-masalah berbeda dan keluarannya menjadi masukan tahap berikutnya.



Gambar 3: Pipeline empat tahap AEO. Setiap tahap memakai paradigma pembelajaran yang berbeda sesuai sifat sub-masalahnya.

3.2.1. Justifikasi Pemilihan Algoritma

Setiap pilihan algoritma diambil melalui pertimbangan eksplisit terhadap alternatif dan berpijak pada literatur masing-masing bidang, bukan karena popularitas.


Tabel 4: Keputusan pemilihan algoritma dan alasan penolakan alternatif

Tahap	Dipilih	Alternatif yang Ditolak dan Alasannya
Deteksi	Isolation Forest [9, 10]	<i>Autoencoder/LSTM</i> ditolak: sejalan dengan tinjauan Chandola dkk. [11], keunggulannya baru terasa pada data berdimensi sangat tinggi, bukan tabel fitur beragregasi seperti milik kami. Isolation Forest dipilih karena tidak memerlukan label anomali — kritis, karena label eksepsi tidak tersedia — dan isolasi rekursifnya lebih efisien dibanding pendekatan berbasis jarak/kepadatan [9].
Kuantifikasi	LightGBM [12]	Regresi linear ditolak: hubungan <code>delay_days</code> terhadap kerugian tidak linear. <i>Deep learning</i> ditolak: pada data tabular menengah, <i>gradient boosting</i> umumnya unggul dengan biaya latih jauh lebih rendah [12]. LightGBM dipilih atas XGBoost [13] karena dua teknik yang diklaim mempercepat pelatihan tanpa kehilangan akurasi berarti pada data tabular berukuran menengah seperti milik kami — <i>Gradient-based One-Side Sampling</i> (GOSS) dan <i>Exclusive Feature Bundling</i> (EFB) [12].
Optimasi	OR-Tools CP-SAT [14]	<i>Greedy</i> ditolak: tidak menjamin optimalitas dan tidak menangani kendala kelayakan. <i>Constraint programming</i> [15] memberi jaminan optimalitas dengan kendala deklaratif yang mudah diperluas; CP-SAT memadukan <i>constraint propagation</i> dengan SAT modern [14].
Mitigasi	LightGBM + LLM	Template statis ditolak: terbaca robotik — sejalan dengan Verbeke dkk. [16] bahwa prediksi churn baru bernilai bisnis bila diikuti aksi retensi personal, bukan komunikasi generik. LLM <i>fine-tune</i> penuh ditolak: berlebihan untuk pesan pendek; <i>prompt</i> terstruktur bersuhu terkendali sudah memadai dan jauh lebih murah.

3.2.2. Tahap 1: Deteksi Anomali (Isolation Forest)

Tahap pertama memakai tiga detektor terpisah, mengikuti kaidah Chandola dkk. [11] bahwa pemilihan teknik deteksi anomali harus mempertimbangkan ketersediaan label serta granularitas yang relevan secara domain. Keputusan memisahkan — alih-alih satu model besar multi-kelas — diambil karena ketiga sinyal beroperasi pada **granularitas entitas yang berbeda**: produk per

hari, penjual, dan pesanan. Menggabungkannya akan memaksa agregasi yang menghilangkan resolusi sinyal.



Gambar 4: Ensemble tiga detektor. Ketiganya beroperasi pada granularitas entitas berbeda, lalu keluarannya diseragamkan ke skala probabilitas yang sama.

Inovasi tim pada tahap ini terletak pada dua hal:

1. **Normalisasi sigmoid pada skor mentah.** Keluaran asli `decision_function` Isolation Forest adalah bilangan riil tak terbatas yang tidak dapat diinterpretasi operator maupun dibandingkan antar detektor. Kami memetakannya ke $[0, 1]$ melalui $p = 1/(1 + e^{3s})$. Faktor pengali 3 dipilih karena nilai lebih rendah membuat distribusi skor terlalu datar (hampir semua kasus jatuh di sekitar 0,5 sehingga tidak diskriminatif), sedangkan nilai lebih tinggi melempar kasus *borderline* langsung ke ekstrem.
2. **Arsitektur hibrida pada SupplierDelayDetector.** Detektor ini memadukan Isolation Forest atas riwayat penjual dengan *z-score* atas *lead time* berbobot 0,5/0,5. Alasannya operasional, bukan statistik: keterlambatan pemasok adalah eksepsi yang **paling sering dipertanyakan operator** karena berimplikasi pada hubungan dagang. Komponen *z-score* memberi penjelasan yang dapat diucapkan — “pemasok ini 3,2 simpangan baku lebih lambat dari biasanya” — sementara Isolation Forest menangkap pola multivariat yang luput dari aturan tunggal.

Ambang *contamination* dibedakan: 5% untuk lonjakan permintaan (kejadian benar-benar jarang) dan 10% untuk keterlambatan (proporsi bermasalah secara empiris lebih tinggi pada data). Ketiga model disimpan sebagai berkas `.pkl` dan dimuat secara *lazy* saat pertama dipanggil.

3.2.3. Tahap 2: Kuantifikasi Dampak (LightGBM)

Dua model LightGBM terpisah menjawab dua pertanyaan berbeda, dan pemisahan ini disengaja: probabilitas pelanggaran SLA adalah masalah klasifikasi atas seluruh populasi pesanan, sedangkan besaran kerugian hanya bermakna **pada pesanan yang memang melanggar**. Melatih regresi kerugian atas seluruh populasi akan didominasi nilai nol dan menghasilkan estimasi yang bias ke bawah.

Tabel 5: Spesifikasi model kuantifikasi dampak

Aspek	SLABreachModel	ExpectedLossModel
Tugas	Klasifikasi biner	Regresi
Objective	binary	regression_l1
Metrik	AUC	MAE
Himpunan latih	Seluruh pesanan berlabel sla_breach	Hanya pesanan dengan sla_breach = 1
Learning rate	0,05	0,05
num_leaves	31	31
Regularisasi	feature_fraction 0,8; bagging_fraction 0,8	—
Early stopping	30 ronde	30 ronde
Keluaran	Probabilitas [0, 1]	Kerugian per pesanan, dikonversi ke IDR


Fungsi kerugian *proxy* dirumuskan sebagai

$$\text{loss} = \text{order_value} \times \min(\max(\text{delay_days}, 0) \times 0,05, 0,5),$$

yaitu setiap hari keterlambatan menambah 5% nilai pesanan sebagai potensi kompensasi, dibatasi maksimum 50%. **Kami menyatakan secara terbuka bahwa kedua konstanta ini adalah asumsi kebijakan, bukan hasil estimasi dari data.** Batas atas 50% dipilih karena melampaui itu, kompensasi menjadi tidak rasional secara bisnis dibanding sekadar membatalkan dan mengembalikan dana penuh. Pada penerapan nyata, kedua konstanta harus diganti dengan tabel kompensasi aktual perusahaan — keduanya diisolasi sebagai parameter tunggal di kode agar penggantian bersifat satu baris.

3.2.4. Tahap 3: Optimasi Pemulihan (OR-Tools CP-SAT)

Tahap ketiga memilih satu aksi pemulihan optimal dari himpunan kandidat yang telah didefinisikan per jenis eksepsi (masing-masing tiga kandidat, mencakup opsi “tidak melakukan apa-apa” sebagai *baseline* pembanding).



Gambar 5: Alur optimasi pemulihan. Kendala kelayakan menyaring kandidat sebelum optimasi, sehingga solver tidak pernah merekomendasikan opsi yang secara operasional mustahil.

Formulasi ini mengikuti kerangka baku pemrograman bilangan bulat [15]: variabel keputusan biner x_i , fungsi objektif linear, dan kendala keanggotaan tunggal (*exactly-one*). Fungsi skor setiap kandidat i merupakan penjumlahan tiga komponen:

$$\text{score}_i = \left\lfloor \frac{\text{expected_loss}_i}{K} \right\rfloor + \underbrace{(1 - f_i) \cdot \frac{\text{baseline_loss}}{K}}_{\text{penalti kelayakan}} + \underbrace{\max(0, \ell_i - \Delta) \cdot \frac{10^6}{K}}_{\text{penalti lead time}}$$

dengan f_i kelayakan, ℓ_i *lead time* kandidat, Δ toleransi keterlambatan, dan $K = 1000$ faktor skala ke bilangan bulat.

Tiga keputusan desain pada formulasi ini perlu dijelaskan. **Pertama**, penskalaan $K = 1000$ diperlukan karena CP-SAT bekerja pada domain bilangan bulat sementara nilai kerugian berada pada orde ratusan juta rupiah; tanpa penskalaan, ruang pencarian membengkak tanpa manfaat presisi. **Kedua**, penalti *lead time* diberi pengali 10^6 agar bersifat mendekati kendala keras — opsi yang datang terlambat dari batas toleransi praktis tidak akan pernah terpilih, tetapi tetap muncul di daftar agar operator melihat bahwa opsi itu dipertimbangkan dan ditolak. **Ketiga**, batas waktu solver satu detik ditetapkan agar keseluruhan respons API tetap berada dalam rentang interaktif; untuk ruang kandidat sekecil ini, CP-SAT mencapai optimalitas jauh di bawah batas tersebut.

3.2.5. Tahap 4: Autonomous Commerce Mitigation (LightGBM + Gemini 2.5 Flash)

Modul ACM menangani konsekuensi yang paling sering diabaikan sistem rantai pasok: **pelanggan yang sudah terlanjur dirugikan**. Modul ini terdiri atas tiga komponen.

(a) ChurnPredictionModel. Pengklasifikasi biner LightGBM (*num_leaves* 15, *learning rate* 0,05, *early stopping* 20 ronde) atas fitur *order_count*, *total_spend_log*, *avg_review*, *late_deliveries*, dan *clv_score*. Parameter *num_leaves* sengaja dibuat separuh dari model dampak: jumlah pelanggan jauh lebih sedikit dari jumlah pesanan, sehingga kapasitas model yang lebih besar akan *overfit*.

Label churn dibentuk sebagai *proxy* orisinal tim: pelanggan ditandai berisiko jika *avg_review* $< 3,5$ **atau** *late_deliveries* > 1 . Disjungsi dipilih sengaja karena keduanya jalur kekecewaan independen — pelanggan bisa kecewa karena kualitas produk meski pengiriman lancar, atau sebaliknya. Mensyaratkan keduanya sekaligus akan melewatkan sebagian besar populasi berisiko, konsisten dengan Verbeke dkk. [16] bahwa performa prediksi churn bergantung pada fitur perilaku yang menangkap lebih dari satu jalur ketidakpuasan.

(b) Sistem voucher bertingkat berbasis CLV. Segmentasi kompensasi mengikuti prinsip pemasaran berbasis CLV: nilai pelanggan bervariasi tajam antar segmen dan alokasi retensi seharusnya proporsional terhadapnya, bukan seragam [6, 17]. Fader, Hardie, & Lee [17] menunjukkan skor *RFM* dapat dipetakan menjadi kurva nilai berjenjang — struktur yang sejalan dengan tiga tingkatan voucher kami.

Tabel 6: Tingkatan kompensasi berdasarkan skor CLV

Tingkatan	Skor CLV	Nominal
Premium Apology Voucher	$\geq 0,7$	Rp 50.000
Standard Apology Voucher	$\geq 0,4$	Rp 25.000
Courtesy Voucher	$< 0,4$	Rp 10.000

Manfaat bersih dihitung sebagai $\max(0, \text{churn_cost} - \text{intervention_cost})$, dengan $\text{churn_cost} =$

$p_{sla} \times affected_customers \times avg_order_value \times 0,3$. Faktor 0,3 merepresentasikan porsi nilai pelanggan yang hilang bila churn terjadi dan — sebagaimana konstanta kerugian pada Tahap 2 — merupakan asumsi kebijakan yang dapat dikonfigurasi, bukan hasil estimasi data.


(c) **Integrasi Gemini 2.5 Flash.** Tiga endpoint memakai modul `models/llm.py` yang memanggil Gemini melalui **REST murni** (`urllib.request`) tanpa SDK, sehingga tidak menambah satu pun dependensi *pip*:

- `/api/explain` — penjelasan tiga kalimat (suhu 0,3) mengapa opsi terpilih meminimalkan biaya total, bagaimana ia menurunkan risiko SLA, dan kendala utama yang menentukan pilihan. Suhu rendah dipilih karena keluaran harus konsisten dan faktual.
- `/api/acm/message` — pesan WhatsApp siap kirim berbahasa Indonesia (suhu 0,7). Suhu lebih tinggi dipilih agar pesan tidak terbaca seragam antar pelanggan.
- `/api/market-sentiment` — klasifikasi ruang lingkup gangguan, lokal atau berskala industri (suhu 0,4).

Seluruhnya memiliki **fallback terstruktur**: bila `GEMINI_API_KEY` tidak tersedia atau kuota habis, fungsi mengembalikan template yang tetap berisi angka nyata dari pipeline — bukan pesan galat. Ini konsekuensi langsung dari prinsip bahwa lapisan LLM bersifat menambah nilai penyajian, bukan menjadi titik kegagalan tunggal.

3.3. Alur Integrasi Model ke Environment Kode

3.3.1. Arsitektur Sistem




Gambar 6: Arsitektur dua-tier. Lapisan model terpisah bersih dari lapisan API — setiap model hanya mengekspos metode `predict()` atau `score()` dan tidak mengetahui keberadaan HTTP.

Pemisahan pada Gambar 6 bukan sekadar penataan berkas: model dapat diuji tanpa menjalankan server, dan lapisan API dapat diganti tanpa menyentuh kode model. Inilah yang kami maksud dengan modularitas — ketiadaan kebergantungan melingkar antar lapisan.

3.3.2. Alur Integrasi Langkah demi Langkah

1. **Persiapan data dan pelatihan (sekali jalan).** Dataset ditempatkan di backend/data/raw/olist/. Perintah python models/train.py menjalankan seluruh *feature engineering*, lalu melatih enam model berurutan. Setiap model disimpan sebagai .pkl melalui joblib di models/artifacts/.
2. **Inisialisasi backend.** FastAPI dijalankan dengan uvicorn main:app -port 8000. Model tidak dimuat saat *startup* melainkan pada pemanggilan pertama (*lazy loading*), sehingga proses *boot* tetap cepat dan kontainer siap menerima *health check* tanpa menunggu deserialisasi seluruh model.
3. **Orkestrasi endpoint.** GET /api/exceptions/demo menjalankan pipeline penuh untuk tiga skenario dan mengembalikan antrian eksepsi yang telah lengkap dianalisis dalam satu respons.
4. **Persetujuan Human-in-the-Loop.** Operator meninjau detail eksepsi beserta rekomendasi. Tombol persetujuan hanya mengubah status di localStorage — **tidak ada integrasi ERP/WMS pada MVP**, sesuai batasan ruang lingkup. Seluruh pemrosesan bersifat **sinkron**: setiap panggilan API selesai dalam satu siklus *request-response*, tanpa *background job*, antrian pesan, maupun basis data terdistribusi.
5. **Deployment.** Satu perintah docker compose up -build menjalankan kedua layanan. Frontend di port 3000, backend di 8000, dan dokumentasi Swagger di /docs.



Gambar 7: Urutan panggilan satu siklus inferensi penuh. Seluruh alur sinkron; kegagalan pada Gemini tidak menghentikan alur karena tertangani *fallback*.

3.3.3. Ringkasan Endpoint API

Tabel 7: Endpoint API AEO

Metode	Path	Fungsi
GET	/health	Status backend dan ketersediaan artefak model
POST	/api/detect	Skoring anomali Isolation Forest
POST	/api/impact	Probabilitas SLA <i>breach</i> + estimasi kerugian
POST	/api/optimize	Opsi pemulihan terurut dari CP-SAT
POST	/api/acm	Skor churn + rekomendasi voucher
POST	/api/explain	Penjelasan rekomendasi berbahasa alami
POST	/api/acm/message	Pesan pelanggan berbahasa Indonesia
POST	/api/market-sentiment	Klasifikasi lingkup gangguan
GET	/api/exceptions/demo	Pipeline penuh untuk tiga skenario demonstrasi

4. Metode Pendukung Pengambilan Keputusan

Selain empat tahap utama, AEO menerapkan sejumlah metode yang secara kolektif menentukan apakah rekomendasi sistem **benar-benar dipakai** operator. Ini bukan hiasan: sistem AI yang akurat tetapi tidak dipercaya tidak menghasilkan nilai apa pun.

4.1. Lapisan Explainability

Setiap rekomendasi disertai penjelasan tiga poin: mengapa opsi ini dipilih, berapa kerugian yang dihindari, dan kendala apa yang menentukan. Literatur *interpretable machine learning* menegaskan penjelasan hanya bernilai bila *fidelity*-nya terhadap model asli terjaga [18]: metode seperti LIME [19] dan SHAP [20] membangun penjelasan lokal langsung dari perilaku model, bukan narasi yang dikarang ulang. Prinsip yang sama kami tegakkan secara arsitektural: penjelasan dibangun dari **angka yang benar-benar dihasilkan solver**; LLM hanya memformat kalimat, tidak menghitung.

4.2. Stratifikasi Severity

Setiap eksepsi memperoleh label *severity* (Critical/High/Medium) dari kombinasi *anomaly_score*, *sla_breach_prob*, dan *expected_loss_idr*. Stratifikasi ini memungkinkan pengurutan otomatis sehingga operator selalu menangani yang paling kritis lebih dahulu. Tanpa ini, kuantifikasi kerugian pada Tahap 2 hanya menjadi angka tanpa konsekuensi operasional.

4.3. Dynamic Pricing Logic

Ketika pelanggaran SLA terdeteksi, sistem menghitung usulan kenaikan harga (0–2%) pada produk *ready-stock* untuk menutup kerugian logistik:

$$\text{uplift_pct} = \min\left(2, 0, \frac{\text{delay_hours} \times 50.000}{\text{affected_customers} \times \text{avg_order_value}} \times 100\right).$$

Batas atas 2% ditetapkan secara sadar: di atas itu, penyesuaian harga berisiko dipersepsikan sebagai eksploitasi situasi. Ini adalah contoh di mana **batasan etis diterjemahkan langsung menjadi kendala matematis** di dalam kode.

4.4. Competitor-Aware Dynamic Sourcing

Endpoint `/api/market-sentiment` mengklasifikasikan apakah gangguan bersifat lokal atau berskala industri. Perbedaannya menentukan respons: gangguan lokal cukup ditangani reaktif (pemasok cadangan, *rebalancing*), sedangkan gangguan industri menuntut respons proaktif (pemesanan awal, renegotiasi kontrak) — lapisan intelijen yang tidak tersedia pada sistem pemantauan konvensional.

4.5. Demo Fallback dan Konvensi Pengembangan

AEO menerapkan *fallback* berlapis: setiap endpoint memeriksa keberadaan artefak model dan mengembalikan nilai demonstrasi berlabel `"source": "demo_fallback"` bila belum tersedia; lapisan LLM memiliki template terstruktur; dan CP-SAT memakai kandidat terdefinisi sehingga rekomendasi selalu tersedia. Konsekuensinya, `docker compose up -build` berhasil dijalankan **tanpa dataset Olist maupun kunci API** — properti yang kami anggap wajib agar penilaian reproduktibilitas lokal berjalan tanpa hambatan. Seluruh commit mengikuti spesifikasi *Conventional Commits* [21], dan repositori menyertakan `.env.example` sehingga tidak ada kredensial pada *version control*.

5. Business Value dan Tata Kelola

Bagian ini membahas kelayakan adopsi industri dan tata kelola AI — dua aspek penentu apakah prototipe dapat menjadi sistem yang benar-benar dipakai.

5.1. Model Bisnis

AEO diposisikan sebagai **SaaS B2B berlangganan** dengan penetapan harga berjenjang menurut volume pesanan bulanan. Pilihan model ini mengikuti karakteristik nilai yang diberikan: manfaat AEO berbanding lurus dengan jumlah eksepsi yang ditangani, dan jumlah eksepsi berbanding lurus dengan volume pesanan.


Tabel 8: Struktur berlangganan dan segmen sasaran

Paket	Segmen	Volume/bulan	Cakupan
Starter	UMKM naik kelas, <i>seller</i> agregator	< 10 ribu pesanan	Deteksi + kuantifikasi dampak; opsi pemulihan standar
Growth	<i>Brand e-commerce</i> menengah	10–100 ribu	Pipeline penuh + ACM + <i>explainability</i>
Enterprise	Peritel besar, 3PL, distributor	> 100 ribu	Pipeline penuh + integrasi ERP/WMS + kandidat pemulihan khusus + SSO

Struktur biayanya menguntungkan: mayoritas komputasi adalah inferensi *gradient boosting* dan *constraint solving* berskala kecil yang berjalan pada CPU biasa tanpa GPU. Biaya variabel terbesar justru pemanggilan LLM — dan itu pun hanya pada endpoint penyajian yang memiliki *fallback*, sehingga plafon biaya dapat ditetapkan tanpa mengorbankan fungsi inti.

5.2. Analisis Kelayakan Adopsi Industri

Pertanyaan penentu adopsi bukan “apakah AI-nya canggih”, melainkan “apakah manfaatnya melampaui biayanya”. Kami menyusun kerangka kelayakan berbasis manfaat bersih per eksepsi yang dihitung sistem sendiri.




Gambar 8: Kerangka perhitungan manfaat bersih per eksepsi.

Tiga faktor mendukung kelayakan adopsi: **hambatan integrasi rendah** (data pesanan, pengiriman, ulasan sudah dimiliki setiap operator, tanpa sensor baru); **adopsi bertahap** (Tahap 1–2 dapat diaktifkan lebih dahulu sebagai peringatan, Tahap 3–4 menyusul); dan **risiko rendah struktural** (persetujuan manusia wajib, sehingga kegagalan model paling buruk hanya rekomendasi ditolak, bukan kerugian langsung).

Hambatan nyata juga kami nyatakan: kualitas data adalah prasyarat mutlak. Organisasi tanpa pencatatan waktu pengiriman konsisten tidak memperoleh manfaat karena label SLA tak dapat dibentuk — ini kriteria kualifikasi pelanggan, bukan masalah yang diselesaikan model.

5.3. Tata Kelola AI dan Kepatuhan Regulasi



Gambar 9: Empat lapisan tata kelola AEO. Lapisan bawah adalah prasyarat teknis; lapisan atas adalah prasyarat kepercayaan organisasi.

5.3.1. Perlindungan Data Pribadi

AEO dirancang selaras dengan **UU No. 27 Tahun 2022 tentang Pelindungan Data Pribadi** [22] melalui tiga keputusan teknis yang konkret:

- **Minimisasi data.** Fitur model hanya memuat besaran agregat dan turunan perilaku (`order_count`, `total_spend`, `avg_review`, `clv_score`). Tidak ada nama, alamat, nomor telepon, maupun surel yang masuk ke dalam fitur model — identitas pelanggan tidak diperlukan untuk memprediksi risiko churn.
- **Pemisahan personalisasi dari inferensi.** Pesan pelanggan dihasilkan dengan *placeholder* nama, bukan dengan mengirimkan identitas pelanggan ke layanan LLM eksternal. Pengga-

bungan nama terjadi di sisi pengirim, setelah teks kembali.

- **Pengelolaan kredensial.** Kunci API dibaca dari variabel lingkungan; repositori hanya memuat `.env.example`.

5.3.2. Klasifikasi Risiko dan Standar Internasional

Merujuk kerangka klasifikasi risiko **EU AI Act** [23], AEO tergolong sistem **risiko terbatas**: ia menghasilkan rekomendasi operasional bagi pengguna profesional, tidak melakukan penilaian terhadap hak individu, tidak digunakan untuk keputusan kepegawaian, kredit, maupun penegakan hukum. Kewajiban utama pada kategori ini adalah transparansi — pengguna harus mengetahui bahwa mereka berinteraksi dengan sistem AI dan memahami dasar keluarannya. Kewajiban ini dipenuhi lewat Lapisan 2 dan 3 pada Gambar 9.

Praktik yang kami terapkan juga selaras dengan fungsi inti **NIST AI Risk Management Framework** [24] — *Govern, Map, Measure, Manage* — serta prinsip sistem manajemen AI pada **ISO/IEC 42001:2023** [25]. Kami tidak mengklaim sertifikasi; yang kami klaim adalah bahwa arsitektur ini tidak memerlukan perombakan untuk menuju kepatuhan, karena jejak audit dan kendali manusia sudah menjadi bagian desain sejak awal, bukan tambalan.

5.3.3. Etika dan Sistem Cerdas yang Bertanggung Jawab

Tiga risiko etis kami identifikasi secara terbuka beserta mitigasinya:

Tabel 9: Risiko etis yang teridentifikasi dan mitigasinya

Risiko	Penjelasan	Mitigasi dalam Sistem
Bias terhadap pelanggan bernilai rendah	Kompensasi berbasis CLV berpotensi memperlakukan pelanggan kecil secara tidak adil.	Ditetapkan rantai kompensasi : setiap pelanggan terdampak menerima voucher, terlepas dari CLV. Tingkatan mengatur besaran, bukan kelayakan menerima.
Bias terhadap pemasok kecil	Pemasok bervolume rendah memiliki varians lebih tinggi sehingga lebih mudah ditandai anomali.	Skor keandalan dinormalisasi terhadap riwayat pemasok itu sendiri, bukan terhadap populasi. Rekomendasi pemasok cadangan bersifat usulan, selalu memerlukan persetujuan manusia.
Eksplorasi harga saat gangguan	<i>Dynamic pricing</i> berpotensi menaikkan harga berlebihan ketika pasokan langka.	Batas keras 2% tertanam di kode, bukan sekadar kebijakan tertulis — kenaikan di atas itu secara teknis tidak dapat dihasilkan sistem.

Kami juga menegaskan batas peran sistem: AEO tidak mengambil keputusan pemutusan hubungan dagang dengan pemasok. Skor keandalan bersifat informatif untuk keputusan operasional jangka pendek. Keputusan yang menyangkut hubungan komersial jangka panjang berada sepenuhnya di luar lingkup sistem, dan pemisahan ini disengaja.

6. Proses Pengembangan Iteratif

Produk ini tidak dibangun sekali jadi. Bagian ini merekam keputusan yang berubah selama pengembangan beserta alasannya — termasuk yang gagal.

Tabel 10: Catatan iterasi: keputusan, pemicu perubahan, dan hasil

Iterasi	Rancangan Awal	Perubahan dan Alasannya
Deteksi	Satu model anomali tunggal.	Dipecah menjadi tiga detektor. Model tunggal memaksa agregasi ke granularitas terkasar; lonjakan produk-per-hari hilang tertelan rata-rata.
Skoring	Skor mentah <code>decision_function</code> .	Ditambahkan normalisasi sigmoid. Skor mentah tak sebanding antar detektor, sehingga stratifikasi <i>severity</i> mustahil disusun.
Kuantifikasi	Satu regresi atas seluruh pesanan.	Dipisah menjadi klasifikasi + regresi bersyarat. Regresi atas populasi penuh didominasi nol, bias ke bawah pada kasus terpenting.
Optimasi	Pengurutan <i>greedy</i> .	Diganti CP-SAT. <i>Greedy</i> memilih opsi termurah yang mustahil operasional karena <i>lead time</i> melewati batas; kendala perlu deklaratif, bukan tambalan <i>if</i> .
Lapisan LLM	LLM merekomendasikan aksi.	Dipersempit menjadi penjelasan saja. LLM menghasilkan saran meyakinkan tapi tak konsisten dengan solver: solver menghitung, LLM memformat.
Ketahanan	Bergantung penuh pada artefak dan kunci API.	Ditambahkan <i>fallback</i> berlapis. Demonstrasi gagal total tanpa artefak terlatih; setiap dependensi eksternal kini punya jalur mundur.

Benang merah seluruh iterasi ini adalah prinsip yang baru kami rumuskan belakangan: **setiap komponen harus punya satu tanggung jawab yang dapat diverifikasi**. Ketika prinsip ini kami langgar — terutama saat membiarkan LLM merekomendasikan aksi — sistem menjadi tidak dapat diaudit dan kesalahan tidak dapat dilacak ke komponen mana pun.

7. Ruang Lingkup MVP, Keterbatasan, dan Rencana Pengembangan

7.1. Batas Ruang Lingkup yang Ditetapkan

Batas ruang lingkup ditetapkan eksplisit agar penilaian dapat dilakukan terhadap sesuatu yang jelas.

Tabel 11: Ruang lingkup MVP: yang dibangun dan yang sengaja tidak dibangun

Lapisan	Termasuk dalam MVP	Sengaja Dikecualikan
Frontend	Alur interaksi inti: antrian eksepsi → detail → rekomendasi AI → persetujuan.	Autentikasi kompleks, manajemen peran, pengaturan lanjutan. Halaman kontekstual lain bersifat penyajian atas data statis dan tidak memuat logika inferensi.
Backend	Pemrosesan sinkron penuh dalam satu siklus <i>request-response</i> .	<i>Background job</i> , antrian pesan, pencatatan data otomatis, basis data terdistribusi.
Model AI	Inferensi inti dengan parameter statis saat demonstrasi.	<i>Auto-tuning</i> , skrip pengujian massal, <i>feedback loop</i> otomatis, pelatihan ulang daring.

7.2. Keterbatasan yang Kami Akui

Kejujuran mengenai keterbatasan kami nilai lebih berguna bagi evaluasi daripada klaim kesempurnaan. Lima berikut paling signifikan:

1. **Kesenjangan domain dataset.** Model dilatih pada data Brasil; pola statistiknya universal, tetapi kalibrasi absolut kerugian belum tervalidasi terhadap operasi Indonesia. *Keterbatasan paling material dari keseluruhan sistem.*
2. **Label churn bersifat proksi.** Label dibentuk dari ulasan dan keterlambatan, bukan pembelian ulang teramati — berkorelasi dengan churn, tidak identik.
3. **Ruang kandidat pemulihan statis.** Tiga kandidat per jenis eksepsi didefinisikan sebelumnya; solver menjamin optimalitas atas himpunan tersebut, bukan seluruh kemungkinan aksi.
4. **Konstanta ekonomi belum terkalibrasi.** Penalti 5% per hari, batas 50%, dan faktor churn 0,3 adalah asumsi kebijakan, diisolasi sebagai parameter agar dapat diganti tanpa mengubah struktur model.
5. **Belum ada validasi pengguna nyata.** Antarmuka dirancang berdasarkan penalaran atas alur kerja operator, belum diuji bersama operator sungguhan.

7.3. Rencana Pengembangan menuju Babak Final

Arsitektur berlapis memungkinkan pengembangan berikut dilakukan **tanpa perombakan total**, karena setiap perbaikan terlokalisasi pada satu lapisan:

Tabel 12: Prioritas pengembangan dan lapisan yang terdampak

No.	Rencana Pengembangan	Lapisan Terdampak
1	Kalibrasi ulang konstanta ekonomi dengan data operasional Indonesia atau data sintetis struktur biaya lokal.	Parameter, tanpa perubahan model
2	Perluasan kandidat pemulihan menjadi kombinasi (pemulihan terbagi lintas beberapa pemasok).	Modul optimizer saja
3	Pelaporan metrik evaluasi (AUC, MAE, matriks konfusi) sebagai keluaran pelatihan.	Skrip pelatihan
4	Uji kegunaan bersama operator untuk memvalidasi urutan informasi halaman detail.	Frontend
5	Penajaman label churn dengan jendela pembelian ulang.	Pipeline fitur + model ACM

8. Kesimpulan

AEO (AI Exception Orchestrator) menjawab kesenjangan operasional nyata: bukan kekurangan data pada rantai pasok *e-commerce*, melainkan ketiadaan jembatan dari sinyal menuju keputusan. Sistem ini menunjukkan AI dapat dipakai bukan sekadar menganalisis data historis, melainkan untuk **mengorkestrasikan respons** — mendeteksi, mengkuantifikasi dalam rupiah, mengoptimasi pemulihan, dan memitigasi dampak pelanggan sebagai satu alur utuh.

Tiga hal membedakannya dari sistem pemantauan yang ada: ia berhenti bukan pada notifikasi melainkan pada opsi aksi terurut disertai angka kerugian; pemilihan aksi terbukti optimal secara matematis atas kandidat yang layak, bukan penalaran heuristik; dan setiap keputusan dapat dijelaskan, memerlukan persetujuan manusia, serta tercatat untuk audit. Pemisahan tanggung jawab yang kami tegakkan setelah beberapa iterasi — **solver menghitung, LLM menjelaskan, manusia memutuskan** — bukan sekadar pilihan arsitektur, melainkan prasyarat agar sistem dapat diaudit, dan karenanya dapat dipercaya pada operasi sesungguhnya.

Keterbatasan yang masih ada — kesenjangan domain dataset dan konstanta ekonomi yang belum terkalibrasi — telah kami petakan beserta jalur perbaikannya, dan keduanya terlokalisasi pada lapisan parameter, bukan struktur sistem. Arsitektur ini siap dikembangkan pada babak final tanpa perombakan menyeluruh, sejalan dengan tema “*AI for the Backbone of the Economy*”: rantai pasok tangguh adalah tulang punggung ekonomi digital.

Agustus 2026

Tim cupuu

Frederick Allensius
Kang Nicholas Darren Nugroho
Ivan William Lianata
Jennifer Carla
Derry Riccardo

Pustaka

- [1] Google, Temasek, & Bain & Company. *e-Conomy SEA: Southeast Asia's digital decade*. Laporan tahunan ekonomi digital Asia Tenggara.
- [2] M. Christopher & H. Peck. "Building the Resilient Supply Chain." *International Journal of Logistics Management*, vol. 15, no. 2, 2004, hlm. 1–14.
- [3] C. S. Tang. "Robust Strategies for Mitigating Supply Chain Disruptions." *International Journal of Logistics Research and Applications*, vol. 9, no. 1, 2006, hlm. 33–45.
- [4] D. Ivanov. "Predicting the Impacts of Epidemic Outbreaks on Global Supply Chains: A Simulation-Based Analysis on the Coronavirus Outbreak (COVID-19/SARS-CoV-2) Case." *Transportation Research Part E: Logistics and Transportation Review*, vol. 136, 2020.
- [5] F. F. Reichheld & W. E. Sasser Jr. "Zero Defections: Quality Comes to Services." *Harvard Business Review*, vol. 68, no. 5, 1990, hlm. 105–111.
- [6] S. Gupta, D. Hanssens, B. Hardie, W. Kahn, V. Kumar, N. Lin, N. Ravishanker, & S. Sriram. "Modeling Customer Lifetime Value." *Journal of Service Research*, vol. 9, no. 2, 2006, hlm. 139–155.
- [7] S. Amershi, D. Weld, M. Vorvoreanu, A. Fourney, B. Nushi, P. Collisson, J. Suh, S. Iqbal, P. N. Bennett, K. Inkpen, J. Teevan, R. Kikin-Gil, & E. Horvitz. "Guidelines for Human-AI Interaction." *Proceedings of the 2019 CHI Conference on Human Factors in Computing Systems*, 2019, hlm. 1–13.
- [8] Olist & A. Sionek. *Brazilian E-Commerce Public Dataset by Olist*. Kaggle. <https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce>
- [9] F. T. Liu, K. M. Ting, & Z.-H. Zhou. "Isolation Forest." *Proceedings of the 8th IEEE International Conference on Data Mining (ICDM)*, 2008, hlm. 413–422.
- [10] F. T. Liu, K. M. Ting, & Z.-H. Zhou. "Isolation-Based Anomaly Detection." *ACM Transactions on Knowledge Discovery from Data (TKDD)*, vol. 6, no. 1, 2012, artikel 3.
- [11] V. Chandola, A. Banerjee, & V. Kumar. "Anomaly Detection: A Survey." *ACM Computing Surveys*, vol. 41, no. 3, 2009, artikel 15.
- [12] G. Ke, Q. Meng, T. Finley, T. Wang, W. Chen, W. Ma, Q. Ye, & T.-Y. Liu. "LightGBM: A Highly Efficient Gradient Boosting Decision Tree." *Advances in Neural Information Processing Systems (NeurIPS)*, 2017.
- [13] T. Chen & C. Guestrin. "XGBoost: A Scalable Tree Boosting System." *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD)*, 2016, hlm. 785–794.
- [14] L. Perron & V. Furnon. *OR-Tools CP-SAT Solver*. Google. https://developers.google.com/optimization/cp/cp_solver
- [15] L. A. Wolsey. *Integer Programming*. Wiley-Interscience, 1998.
- [16] W. Verbeke, K. Dejaeger, D. Martens, J. Hur, & B. Baesens. "New Insights into Churn Prediction in the Telecommunication Sector: A Profit Driven Data Mining Approach." *European Journal of Operational Research*, vol. 218, no. 1, 2012, hlm. 211–229.
- [17] P. S. Fader, B. G. S. Hardie, & K. L. Lee. "RFM and CLV: Using Iso-Value Curves for Customer Base Analysis." *Journal of Marketing Research*, vol. 42, no. 4, 2005, hlm. 415–430.
- [18] F. Doshi-Velez & B. Kim. "Towards A Rigorous Science of Interpretable Machine Learning." *arXiv preprint arXiv:1702.08608*, 2017.

- [19] M. T. Ribeiro, S. Singh, & C. Guestrin. “‘Why Should I Trust You?’: Explaining the Predictions of Any Classifier.” *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD)*, 2016, hlm. 1135–1144.
- [20] S. M. Lundberg & S.-I. Lee. “A Unified Approach to Interpreting Model Predictions.” *Advances in Neural Information Processing Systems (NeurIPS)*, 2017.
- [21] *Conventional Commits Specification v1.0.0*. <https://www.conventionalcommits.org>
- [22] Republik Indonesia. *Undang-Undang Nomor 27 Tahun 2022 tentang Pelindungan Data Pribadi*.
- [23] European Union. *Regulation (EU) 2024/1689 laying down harmonised rules on artificial intelligence (Artificial Intelligence Act)*.
- [24] National Institute of Standards and Technology. *AI Risk Management Framework (AI RMF 1.0)*. NIST, 2023.
- [25] International Organization for Standardization. *ISO/IEC 42001:2023 — Information technology — Artificial intelligence — Management system*.