

PROPOSAL INOVASI AI

AI Innovation Challenge · COMPFEST 18

“AI for the Backbone of the Economy” — Smart Commerce & Smart Logistics

AEO AI Exception Orchestrator

Sistem Manajemen Eksepsi Rantai Pasok Berbasis AI

Nama Kelompok : cupuu

Institusi : BINUS University, Program Studi Data Science

Anggota Tim : Frederick Allensius
Kang Nicholas Darren Nugroho
Ivan William Lianata

Tahun : 2026

*Proposal ini disusun untuk memenuhi persyaratan
AI Innovation Challenge COMPFEST 18*

Daftar Isi

1	Latar Belakang	2
2	Tujuan dan Manfaat Pengembangan	2
2.1	Tujuan Pengembangan	2
2.2	Manfaat Pengembangan	3
3	Metodologi	3
3.1	Alur Memperoleh Dataset	3
3.1.1	Komposisi Dataset	4
3.1.2	Feature Engineering	4
3.2	Alur Pengembangan Model (Per Fitur/Tahap)	5
3.2.1	Tahap 1: Deteksi Anomali (Isolation Forest)	5
3.2.2	Tahap 2: Kuantifikasi Dampak (LightGBM)	6
3.2.3	Tahap 3: Optimasi Pemulihan (OR-Tools CP-SAT)	6
3.2.4	Tahap 4: Autonomous Commerce Mitigation / ACM (LightGBM + Gemini Flash)	7
3.3	Alur Integrasi Model ke Environment Kode	8
3.3.1	Arsitektur Sistem	8
3.3.2	Alur Integrasi Langkah demi Langkah	8
3.3.3	Ringkasan Endpoint API	10
4	Metode Pendukung Pengambilan Keputusan	10
4.1	Inovasi Model dan Fine-Tuning per Tim	10
4.2	Explainability Layer (Penjelasan Rekomendasi AI)	11
4.3	Dynamic Pricing Logic	11
4.4	Human-in-the-Loop (HITL) Governance	11
4.5	Severity Stratification	12
4.6	Demo Fallback System (Graceful Degradation)	12
4.7	Konvensi Pengembangan dan Repositori	12
4.8	Decision History Log (Audit Trail)	12
4.9	Competitor-Aware Dynamic Sourcing (Market Sentiment)	13
5	Kesimpulan	13

1. Latar Belakang

Industri *e-commerce* Indonesia mengalami pertumbuhan yang signifikan — pada tahun 2023, nilai transaksi digital nasional melampaui USD 82 miliar dan diproyeksikan terus meningkat seiring penetrasi internet yang kian luas. Di balik angka pertumbuhan ini, **rantai pasok** (*supply chain*) menjadi infrastruktur yang paling rentan: setiap gangguan kecil pada pengiriman, ketersediaan stok, atau kinerja pemasok berdampak langsung pada pengalaman pelanggan dan kerugian finansial bisnis.

Dalam operasional *e-commerce* berskala besar, eksepsi rantai pasok — seperti lonjakan permintaan mendadak (*demand spike*), keterlambatan pemasok (*supplier delay*), dan gangguan pengiriman (*shipment delay*) — terjadi hampir setiap hari. Namun penanganannya masih banyak dilakukan secara **manual**: operator memantau *dashboard*, mengidentifikasi masalah, menegosiasikan solusi pemulihan, dan menginformasikan pelanggan — semua secara bertahap dan memakan waktu.

Masalah ini diperparah oleh tiga kesenjangan utama:

1. **Kesenjangan deteksi**: eksepsi baru diketahui setelah SLA dilanggar, bukan ketika pola anomali mulai terdeteksi.
2. **Kesenjangan kuantifikasi**: tidak ada cara cepat untuk memperkirakan dampak finansial (dalam Rupiah) dari setiap eksepsi sehingga prioritas dilakukan secara intuitif.
3. **Kesenjangan respons**: tidak ada sistem yang secara otomatis merekomendasikan aksi pemulihan terbaik beserta perkiraan biaya dan risikonya.

Solusi yang ada saat ini bersifat reaktif, berbasis aturan statis, dan tidak mampu belajar dari pola historis. **AEO (AI Exception Orchestrator)** hadir untuk menutup ketiga kesenjangan ini melalui pipeline kecerdasan buatan empat tahap yang bekerja secara berurutan: mendeteksi anomali, mengkuantifikasi dampak, mengoptimalkan pemulihan, dan memitigasi risiko churn pelanggan — semuanya dalam hitungan detik dan tetap dengan manusia sebagai pemegang keputusan akhir.

2. Tujuan dan Manfaat Pengembangan

2.1. Tujuan Pengembangan

Pengembangan AEO bertujuan untuk:

1. Membangun sistem deteksi anomali rantai pasok secara *real-time* menggunakan *ensemble* Isolation Forest yang mampu mengidentifikasi lonjakan permintaan, keterlambatan pemasok, dan gangguan pengiriman secara bersamaan dan independen.
2. Mengkuantifikasi dampak finansial dari setiap eksepsi menggunakan model prediktif

berbasis LightGBM, memberikan estimasi kerugian dalam Rupiah agar operator dapat memprioritaskan penanganan berdasarkan data — bukan perkiraan.

3. Mengotomasi rekomendasi aksi pemulihan optimal menggunakan *solver constraint programming* (OR-Tools CP-SAT dari Google), memastikan opsi yang direkomendasikan adalah solusi dengan total biaya minimum yang layak secara operasional.
4. Mengurangi risiko *churn* pelanggan akibat keterlambatan melalui modul ACM (*Autonomous Commerce Mitigation*) yang menggabungkan LightGBM *churn prediction* dengan sistem voucher berbasis CLV (*Customer Lifetime Value*) dan pesan WhatsApp personal berbahasa Indonesia berbantuan Gemini 2.5 Flash.
5. Mempertahankan prinsip **Human-in-the-Loop (HITL)** pada setiap keputusan yang tidak dapat dibatalkan, sehingga AI berperan sebagai asisten cerdas — bukan pengganti operator.

2.2. Manfaat Pengembangan

Tabel 1: Manfaat Pengembangan AEO

Manfaat	Deskripsi
Respons lebih cepat	Deteksi otomatis mempersingkat waktu respons eksepsi dari hitungan jam menjadi detik, mengurangi dampak gangguan sebelum meluas.
Prioritisasi berbasis data	Estimasi kerugian IDR per eksepsi memungkinkan operator memfokuskan perhatian pada gangguan dengan dampak finansial tertinggi.
Retensi pelanggan	Voucher dan pesan personal yang tepat sasaran mengurangi risiko kehilangan pelanggan high-CLV akibat keterlambatan pengiriman.
Keputusan yang aman	Prinsip HITL memastikan tidak ada perubahan sistem yang terjadi tanpa persetujuan manusia, meminimalkan risiko kesalahan AI.
Pipeline terintegrasi	Satu API mengorkestrasikan empat model AI dalam satu alur kerja yang dapat dijalankan langsung dari Docker.
Portabilitas	Dilatih pada dataset publik Olist Brasil yang merepresentasikan pola e-commerce universal; mudah disesuaikan dengan data operasional Indonesia.

3. Metodologi

3.1. Alur Memperoleh Dataset

Dataset yang digunakan adalah **Olist Brazilian E-Commerce Public Dataset** yang tersedia secara terbuka di Kaggle. Dataset ini mencakup **96.475 pesanan** dari tahun 2016 hingga

2018, meliputi data transaksi, informasi pengiriman, ulasan pelanggan, data penjual, dan detail produk — menjadikannya representasi e-commerce lintas kategori yang kaya fitur.

Meskipun berasal dari Brasil, pola operasional e-commerce — distribusi keterlambatan pengiriman, perilaku pelanggan pasca-keterlambatan, dan profil risiko pemasok — bersifat universal dan dapat divalidasi sebagai *proxy* untuk konteks Indonesia sebelum data operasional lokal tersedia.

3.1.1. Komposisi Dataset

Dataset terdiri dari delapan file CSV yang ditempatkan di direktori `backend/data/raw/olist/`:

Tabel 2: File Dataset Olist

Nama File	Konten
<code>olist_orders_dataset.csv</code>	Data utama pesanan dengan timestamp dan status
<code>olist_order_items_dataset.csv</code>	Item per pesanan dan ID penjual
<code>olist_order_payments_dataset.csv</code>	Nilai pembayaran per pesanan
<code>olist_order_reviews_dataset.csv</code>	Skor ulasan pelanggan
<code>olist_customers_dataset.csv</code>	Data pelanggan
<code>olist_sellers_dataset.csv</code>	Data penjual/pemasok
<code>olist_products_dataset.csv</code>	Kategori dan atribut produk
<code>product_category_name_translation.csv</code>	Terjemahan kategori produk

3.1.2. Feature Engineering

Script `backend/data/pipeline.py` menghasilkan empat tabel fitur yang masing-masing dikonsumsi oleh model yang sesuai:

Tabel 3: Tabel Fitur Hasil Feature Engineering

Fungsi Pipeline	Output	Fitur Utama
build_order_features	Per-order features	delay_days, carrier_delay_days, sla_breach, order_value, purchase_hour/dow/month, item_count
build_demand_timeseries	Daily velocity per produk	order_count, rolling_mean_7d, rolling_std_7d, z_score
build_seller_features	Per-seller reliability	mean_delay, std_delay, late_rate, reliability (0–1)
build_customer_features	Per-customer CLV & churn	clv_score, total_spend, avg_review, late_deliveries, churn_risk_label

3.2. Alur Pengembangan Model (Per Fitur/Tahap)

AEO memiliki empat tahap AI yang bekerja secara berurutan membentuk satu pipeline inferensi. Setiap tahap menyelesaikan satu sub-masalah yang berbeda dan menghasilkan output yang menjadi input bagi tahap berikutnya.

Tahap 1	Tahap 2	Tahap 3	Tahap 4
Deteksi Anomali	Kuantifikasi Dampak	Optimasi Pemulihan	Mitigasi Pelanggan
Isolation Forest ×3	LightGBM	OR-Tools CP-SAT	LightGBM + Gemini 2.5 Flash
anomaly_score	sla_breach_prob	ranked options	voucher + WA msg

Gambar 1: Pipeline Empat Tahap AEO

3.2.1. Tahap 1: Deteksi Anomali (Isolation Forest)

Tahap pertama menggunakan *ensemble* tiga Isolation Forest yang masing-masing dilatih pada sinyal yang berbeda:

1. DemandSpikeDetector

Isolation Forest dengan 200 estimator dan *contamination* 5%, dilatih pada fitur *rolling demand velocity* per produk: `order_count`, `rolling_mean_7d`, `rolling_std_7d`, dan `z_score`. Output berupa probabilitas anomali 0–1 yang diperoleh dari transformasi sigmoid terhadap *decision function* Isolation Forest: $p = 1/(1 + e^{s^3})$ di mana s adalah *raw decision score*.

2. SupplierDelayDetector

Model *hybrid*: Isolation Forest pada *seller history* (`order_count`, `mean_delay`, `std_delay`,

reliability) dikombinasikan dengan *rule-based z-score* pada *lead time*. Skor akhir merupakan rata-rata berbobot: $score = 0.5 \times IFscore + 0.5 \times rulescore$, memberikan tingkat interpretabilitas yang lebih tinggi dibanding Isolation Forest murni. *Contamination* diset 10% untuk mengakomodasi tingginya proporsi pemasok bermasalah.

3. ShipmentDelayDetector

Isolation Forest pada fitur level-order: `carrier_delay_days`, `item_count`, `order_value`. Model ini mendeteksi pengiriman yang secara statistik menyimpang dari baseline historis carrier — bukan sekadar pengiriman yang terlambat, tetapi anomali pola delay yang mengindikasikan masalah sistemik.

Ketiga model disimpan sebagai file `.pkl` di `backend/models/artifacts/` menggunakan `joblib` dan dimuat secara *lazy* saat pertama kali dipanggil.

3.2.2. Tahap 2: Kuantifikasi Dampak (LightGBM)

Dua model LightGBM dilatih secara terpisah untuk menjawab dua pertanyaan berbeda:

Tabel 4: Model Kuantifikasi Dampak

Model	SLABreachModel	ExpectedLossModel
Tugas	Binary classification	Regression
Objective	binary (AUC)	regression_l1 (MAE)
Training set	Semua order dengan label <code>sla_breach</code>	Hanya order yang sudah breach SLA
Output	Probabilitas SLA breach [0–1]	Expected loss dalam IDR
Konversi IDR	–	$loss_BRL \times affected_orders \times 3.000$

Loss *proxy* dihitung sebagai: $loss = order_value \times clip(delay_days \times 0.05, 0.5)$, artinya setiap hari keterlambatan menambah 5% nilai pesanan sebagai potensi kompensasi/refund, dengan batas maksimum 50%.

Parameter LightGBM yang digunakan: `learning_rate=0.05`, `num_leaves=31`, `feature_fraction=0.8`, `bagging_fraction=0.8`, dengan *early stopping* pada 30 ronde.

3.2.3. Tahap 3: Optimasi Pemulihan (OR-Tools CP-SAT)

Tahap ketiga menggunakan **Constraint Programming solver CP-SAT** dari Google OR-Tools untuk memilih satu aksi pemulihan optimal dari kumpulan kandidat yang telah didefinisikan untuk setiap jenis eksepsi.

Kandidat Pemulihan per Jenis Eksepsi:

Tabel 5: Kandidat Aksi Pemulihan

Jenis Eksepsi	Kandidat	Deskripsi Singkat
Supplier Delay	Tunggu pemasok	Tidak ada intervensi; absorb keterlambatan
	Backup supplier	Pindah 100% volume ke pemasok cadangan
	Split supply	60% pemasok lama, 40% cadangan
Demand Spike	Do nothing	Layani <i>first-come-first-served</i>
	Rebalance DC	Transfer stok dari <i>distribution center</i> regional
	Cap listing	Batasi kuantitas pembelian per order
Shipment Delay	Hold & wait	Pertahankan rute laut; notifikasi pelanggan
	Air-freight	Kirim subset kritis via udara
	Reroute	Alihkan via hub carrier alternatif

Formulasi Optimasi:

Setiap kandidat i memiliki skor: $score_i = \lfloor expected_loss_i / K \rfloor + feasibility_penalty_i + lead_time_penalty_i$, di mana $K = 1000$ adalah faktor skala ke integer.

Model CP-SAT meminimalkan: $\min \sum_i score_i \cdot x_i$, dengan *constraint*: $\sum_i x_i = 1$ (exactly-one), $x_i = 0$ jika $feasibility_i < 0.3$, dan $x_i \in \{0, 1\}$.

Solver dijalankan dengan batas waktu maksimum 1 detik (`max_time_in_seconds=1.0`), menghasilkan solusi optimal global dalam waktu respons API yang dapat diterima.

3.2.4. Tahap 4: Autonomous Commerce Mitigation / ACM (LightGBM + Gemini Flash)

Modul ACM terdiri dari tiga komponen yang bekerja secara paralel:

1. ChurnPredictionModel (LightGBM)

Binary classifier dilatih pada fitur pelanggan: `order_count`, `total_spend_log`, `avg_review`, `late_deliveries`, `clv_score`. Label churn dibuat sebagai *proxy*: pelanggan berisiko churn jika rata-rata ulasan < 3.5 **atau** memiliki lebih dari satu pengiriman terlambat. Parameter: `num_leaves=15`, `learning_rate=0.05`, `early_stopping=20`.

2. CLV-Tiered Voucher System

Sistem pemberian voucher kompensasi berdasarkan segmen CLV pelanggan:

Tier	CLV Score	Nominal Voucher
Premium Apology Voucher	≥ 0.7	Rp 50.000
Standard Apology Voucher	≥ 0.4	Rp 25.000
Courtesy Voucher	< 0.4	Rp 10.000

Net benefit dihitung: $net_benefit = \max(0, churn_cost_tanpa_intervensi - intervention_cost)$, di mana $churn_cost = p_{sla} \times affected_customers \times avg_order_value \times 0.3$.

3. Gemini 2.5 Flash Integration

Tiga endpoint LLM disediakan — semuanya berbagi modul `models/llm.py` yang memanggil Gemini via **REST murni** (`urllib.request`) tanpa SDK tambahan, sehingga tidak ada ketergantungan *pip* baru:

- `/api/explain`: menghasilkan penjelasan 3 kalimat (temperature 0.3) dalam Bahasa Inggris mengapa opsi pemulihan tersebut dipilih, berapa kerugian yang dihindari, dan faktor pembatas utama yang diidentifikasi solver.
- `/api/acm/message`: menghasilkan pesan WhatsApp siap-kirim dalam Bahasa Indonesia (temperature 0.7) dengan voucher nominal spesifik, tone personal, dan penutup positif — dimulai dengan "Halo [Nama] ,".
- `/api/market-sentiment` (*Competitor-Aware Dynamic Sourcing*): mengklasifikasikan apakah gangguan bersifat lokal/terisolir atau berskala industri, membantu operator memutuskan agresivitas *procurement* jangka menengah.

Sistem mengimplementasikan ***graceful fallback berlapis dua***: jika variabel `GEMINI_API_KEY` tidak tersedia atau kuota habis, setiap fungsi mengembalikan template terstruktur berisi data numerik nyata dari pipeline (bukan pesan kosong). API key bersifat opsional dan tersedia gratis pada tingkat penggunaan 1.500 *request*/hari pada model `gemini-2.5-flash`.

3.3. Alur Integrasi Model ke Environment Kode

3.3.1. Arsitektur Sistem

AEO dibangun dalam arsitektur dua-tier:

- **Backend**: FastAPI (Python 3.11), berjalan di port 8000, mengorkestrasikan seluruh model AI.
- **Frontend**: React + Vite + TanStack Router + ShadCN, berjalan di port 3000, menyediakan antarmuka operator.

Komunikasi antara frontend dan backend menggunakan REST API dengan format JSON. Kedua layanan dikemas dalam *container* Docker dan diorkestrasikan dengan Docker Compose.

3.3.2. Alur Integrasi Langkah demi Langkah

1. Persiapan Data & Training (one-time)

Dataset Olist ditempatkan di `backend/data/raw/olist/`. Script python `models/train.py` menjalankan seluruh pipeline feature engineering menggunakan `pipeline.py`, kemu-

dian melatih 6 model secara berurutan dalam waktu sekitar 60 detik. Setiap model disimpan sebagai file .pkl menggunakan joblib di direktori `models/artifacts/`.

2. Inisialisasi Backend

FastAPI memuat semua model ke memori saat *startup* (`uvicorn main:app -reload -port 8000`). Setiap model memiliki metode `predict()` yang menerima *dictionary* fitur dan mengembalikan hasil inferensi. Model menggunakan *lazy loading*: jika file .pkl belum ada saat `predict()` dipanggil, model memuat otomatis dari *disk*.

3. Orkestrasi API Endpoint

Endpoint `GET /api/exceptions/demo` mengorkestrasikan seluruh pipeline empat tahap untuk tiga skenario demo (supplier delay, demand spike, shipment delay). Frontend memanggil endpoint ini dan menampilkan antrian eksepsi yang sudah dianalisis lengkap dengan skor anomali, estimasi kerugian, dan opsi pemulihan terurut.

4. Human-in-the-Loop Approval

Operator melihat detail eksepsi beserta rekomendasi AI di halaman detail. Tombol “Approve” hanya mengubah status pesanan di `localStorage` (simulasi MVP — tidak ada integrasi ERP/WMS). Seluruh pemrosesan bersifat **sinkron** tanpa *background job*: setiap API call mengembalikan respons langsung dalam satu *request-response cycle*, sesuai scope MVP. Log keputusan tersimpan di halaman *History* untuk keperluan audit.

5. Antarmuka Operator (Frontend)

React SPA menyediakan beberapa halaman operasional yang saling terintegrasi:

- **Exception Queue**: antrian eksepsi aktif dengan skor anomali, estimasi kerugian IDR, dan badge severity (Critical/High/Medium).
- **Peta Logistik Indonesia**: visualisasi geografis berbasis *react-simple-maps* menampilkan jalur distribusi antarprovinsi dan hub cargo secara *real-time* — sepenuhnya dirender di sisi klien tanpa API peta berbayar.
- **Finance Breakdown**: panel analitik dengan breakdown ROI per jenis eksepsi (Supplier Delay, Demand Spike, Shipment Delay, dan tiga tipe lainnya) dilengkapi footer kalkulasi total net benefit.
- **Halaman Operasional**: halaman Pesanan, Produksi, dan Distribusi dengan data analitik realistis yang menunjukkan konteks bisnis dari setiap eksepsi yang terdeteksi.
- **ACM Panel**: panel mitigasi pelanggan yang menampilkan hasil `/api/acm`, rekomendasi voucher per tier CLV, dan tombol untuk *men-generate* pesan WhatsApp

via Gemini.

- **Decision History:** log audit semua keputusan operator lengkap dengan *timestamp* dan estimasi dampak.

6. Deployment via Docker Compose

Satu perintah `docker compose up -build` membangun dan menjalankan kedua layanan sekaligus. Frontend tersedia di `http://localhost:3000`, backend di `http://localhost:8000` dan dokumentasi API interaktif (Swagger UI) di `http://localhost:8000/docs`. Konfigurasi CORS mendukung port pengembangan 3000, 5173, 5174, dan 4173 sehingga *developer experience* tidak terganggu perbedaan port antar alat.

3.3.3. Ringkasan Endpoint API

Tabel 6: Endpoint API AEO

Metode	Path	Fungsi
GET	/health	Status backend dan model
POST	/api/detect	Isolation Forest anomaly scoring
POST	/api/impact	LightGBM SLA breach + loss prediction
POST	/api/optimize	OR-Tools CP-SAT recovery options
POST	/api/acm	LightGBM churn score + voucher
POST	/api/explain	Gemini Flash: penjelasan rekomendasi AI
POST	/api/acm/message	Gemini Flash: pesan WhatsApp Indonesia
POST	/api/market-sentiment	Gemini: Competitor-Aware Dynamic Sourcing — deteksi lokal vs industri
GET	/api/exceptions/demo	Full pipeline untuk 3 skenario demo

4. Metode Pendukung Pengambilan Keputusan

Selain empat tahap utama AI, AEO mengimplementasikan beberapa metode tambahan yang secara kolektif memperkuat kepercayaan operator terhadap rekomendasi sistem — sebuah aspek krusial dalam adopsi AI di lingkungan operasional kritis.

4.1. Inovasi Model dan Fine-Tuning per Tim

Seluruh model dalam AEO bukan sekadar implementasi *off-the-shelf* — setiap model mengalami **fine-tuning dan inovasi spesifik** yang disesuaikan dengan domain eksepsi rantai pasok:

- **DemandSpikeDetector:** transformasi probabilistik kustom — skor mentah Isolation Forest dikonversi ke probabilitas 0–1 via fungsi sigmoid $p = 1/(1 + e^{s \cdot 3})$, sehingga output lebih mudah diinterpretasi operator dibanding skor *raw decision function*.

- **SupplierDelayDetector:** arsitektur *hybrid* orisinal menggabungkan Isolation Forest (sinyal pola historis) dengan *z-score rule-based* (sinyal lead time): bobot 50/50 memberikan keseimbangan antara kemampuan deteksi anomali statistik dan interpretabilitas aturan bisnis.
- **ChurnPredictionModel:** label `churn_risk_label` dibuat secara kustom dari domain knowledge tim — pelanggan dikategorikan berisiko jika `avg_review < 3.5` **atau** `late_deliveries > 1`, merepresentasikan kombinasi *satisfaction signal* dan *behavioral signal* yang lebih akurat dari threshold tunggal.
- **SLABreachModel + ExpectedLossModel:** dilatih pada subset Olist yang relevan dengan *feature engineering* kustom (`delay_days`, `carrier_delay_days`, `purchase_hour/dow/month`) dan *loss proxy formula* yang dikalibrasi terhadap karakteristik e-commerce Indonesia (5% order value per hari keterlambatan).
- **OR-Tools CP-SAT Scoring:** fungsi objektif multi-komponen kustom — tiga jenis penalti (`expected loss`, `infeasibility`, `lead time overrun`) digabungkan dengan faktor skala $K = 1000$ untuk memastikan solver bekerja pada ruang integer yang stabil dalam batas waktu 1 detik.

4.2. Explainability Layer (Penjelasan Rekomendasi AI)

Setiap rekomendasi AI dilengkapi penjelasan *3-bullet* berbahasa Inggris yang dihasilkan oleh Gemini 2.5 Flash, menjelaskan: (a) mengapa opsi tersebut dipilih, (b) risiko utama yang mungkin terjadi, dan (c) pertimbangan yang harus diverifikasi operator. Pendekatan ini menerapkan prinsip **Explainable AI (XAI)** secara praktis: operator tidak perlu memahami teknik ML untuk mengambil keputusan yang terinformasi.

4.3. Dynamic Pricing Logic

Ketika *SLA breach* terdeteksi, sistem menghitung *dynamic pricing uplift* (0–2%) pada produk *ready-stock* untuk menutup kerugian logistik. Formula:

$$uplift_pct = \min\left(2.0, \frac{delay_hours \times 50.000}{affected_customers \times avg_order_value} \times 100\right)$$

Ini memungkinkan operator membuat keputusan bisnis yang lebih holistik — tidak hanya menangani eksepsi, tetapi juga mengamankan margin.

4.4. Human-in-the-Loop (HITL) Governance

Prinsip HITL diterapkan secara konsisten di seluruh sistem: semua aksi pemulihan berstatus *simulated* hingga operator secara eksplisit menyetujui melalui antarmuka. Tidak ada integrasi ERP atau WMS dalam MVP. Desain ini mencegah kesalahan AI yang berpotensi menyebabkan kerugian nyata sebelum sistem terbukti akurat di lapangan.

4.5. Severity Stratification

Setiap eksepsi mendapat skor *severity* (Critical / High / Medium) berdasarkan kombinasi tiga sinyal: *anomaly_score*, *sla_breach_prob*, dan *expected_loss_idr*. Stratifikasi ini memungkinkan antrian eksepsi diurutkan secara otomatis sehingga operator selalu menangani yang paling kritis terlebih dahulu, tanpa perlu melakukan *triage* manual.

4.6. Demo Fallback System (Graceful Degradation)

AEO mengimplementasikan sistem **demo fallback berlapis** yang memastikan aplikasi tetap dapat didemonstrasikan bahkan sebelum proses training selesai:

- Setiap endpoint (`/api/detect`, `/api/impact`) memeriksa keberadaan file `.pkl` di direktori `models/artifacts/`. Jika belum ada, endpoint mengembalikan nilai demo realistis dengan label `"source": "demo_fallback"`.
- Model LLM (Gemini) memiliki template fallback terstruktur yang mengembalikan analisis numerik nyata dari data pipeline — bukan string kosong — jika `GEMINI_API_KEY` tidak tersedia.
- OR-Tools CP-SAT menggunakan kandidat hard-coded per jenis eksepsi sehingga rekomendasi pemulihan selalu tersedia tanpa dependensi data eksternal.

Desain ini memastikan *zero-crash guarantee*: demo dapat berjalan dengan `docker compose up -build` tanpa dataset Olist maupun API key Gemini.

4.7. Konvensi Pengembangan dan Repositori

Seluruh commit dalam repositori GitHub publik mengikuti standar **Conventional Commits**:

- `feat`: — penambahan fitur baru (model, endpoint, komponen UI)
- `fix`: — perbaikan bug atau tampilan
- `refactor`: — perubahan struktur kode tanpa perubahan fungsionalitas
- `docs`: — dokumentasi (termasuk proposal ini)

Repositori juga menyediakan `.env.example` sebagai template konfigurasi tanpa menyimpan *secret* di *version control*, dan `docker-compose.yml` yang tervalidasi untuk menjalankan seluruh sistem dengan satu perintah sesuai instruksi `README.md`.

4.8. Decision History Log (Audit Trail)

Setiap keputusan operator dicatat dengan *timestamp*, jenis eksepsi, opsi yang dipilih, operator yang bertanggung jawab, dan estimasi dampak sebelum/sesudah intervensi. Halaman *History* menyediakan audit trail lengkap yang penting untuk: analisis *post-mortem* insiden,

pelatihan ulang model dengan data keputusan nyata, dan kepatuhan operasional internal.

4.9. Competitor-Aware Dynamic Sourcing (Market Sentiment)

Endpoint `/api/market-sentiment` mengimplementasikan fitur **Competitor-Aware Dynamic Sourcing**: LLM menganalisis jenis eksepsi dan tingkat keparahannya, lalu menentukan apakah gangguan bersifat *lokal/terisolir* atau *berskala industri* (misalnya: kemacetan pelabuhan, kekurangan komoditas, cuaca ekstrem regional). Klasifikasi ini penting karena:

- Gangguan lokal → respons *reactive* cukup: backup supplier, rebalancing DC.
- Gangguan industri-wide → respons *proactive* diperlukan: pre-order stok jangka panjang, renegosiasi kontrak, atau price hedge.

Output berupa `{scope, summary, source}` di mana `scope` adalah "local" atau "industry-wide", dan `summary` adalah analisis 2-kalimat dari Gemini (atau template terstruktur sebagai fallback). Ini memberikan lapisan intelijen pasar yang tidak tersedia di sistem monitoring tradisional.

5. Kesimpulan

AEO (AI Exception Orchestrator) adalah solusi manajemen eksepsi rantai pasok yang dirancang untuk menjawab celah operasional nyata dalam industri e-commerce Indonesia. Sistem ini membuktikan bahwa AI dapat diterapkan tidak hanya untuk menganalisis data historis, tetapi untuk **mengorkestrasikan respons real-time** terhadap gangguan operasional yang kompleks.

Dengan pipeline empat tahap yang terintegrasi — deteksi anomali berbasis Isolation Forest, kuantifikasi dampak finansial melalui LightGBM, optimasi pemulihan menggunakan CP-SAT solver, dan mitigasi pelanggan proaktif dengan LightGBM serta Gemini 2.5 Flash — AEO memberikan nilai tambah di setiap titik keputusan: dari identifikasi masalah awal hingga komunikasi pelanggan akhir.

Yang membedakan AEO dari solusi pemantauan rantai pasok yang ada adalah **filosofi desainnya**: AI bukan pengganti manusia, melainkan *amplifier* kapasitas operator. Setiap rekomendasi dapat dijelaskan, setiap keputusan memerlukan persetujuan manusia, dan setiap aksi dicatat untuk keperluan audit dan iterasi. Ini bukan sekadar fitur — ini adalah fondasi yang memungkinkan adopsi AI yang bertanggung jawab dalam lingkungan operasional kritis.

Tim cupuu dari BINUS University Data Science meyakini bahwa inovasi ini memiliki potensi implementasi nyata di perusahaan logistik dan e-commerce Indonesia, sejalan dengan tema kompetisi “*AI for the Backbone of the Economy*” — karena rantai pasok yang tangguh dan responsif adalah tulang punggung ekonomi digital yang dapat diandalkan.

Jakarta, Agustus 2026

Tim cupuu

BINUS University, Data Science

Frederick Allensius

Kang Nicholas Darren Nugroho

Ivan William Lianata